

Sezione 1 - Pre-elaborazione dei dati

Obiettivo della fase

Questa prima parte del progetto ha avuto lo scopo di importare il dataset di espressione genica, rimuovere le colonne non necessarie, ricostruire le coppie matched Tumor/Normal e preparare una matrice numerica adatta alla successiva analisi differenziale. La procedura segue il flusso previsto dalla traccia del progetto, partendo dall'importazione del dataset fino alla costruzione della matrice filtrata da usare nelle analisi successive.

1.1 Importazione e pulizia iniziale

In questa prima fase ho importato il dataset GSE32863 in RStudio e ho controllato la struttura iniziale del file. Il dataset conteneva 48803 sonde e 233 colonne, perché ai valori di espressione erano alternate anche colonne relative ai Detection P-value. Poiché l'analisi differenziale richiede soltanto i valori di espressione, ho rimosso queste colonne e ho mantenuto una matrice di 48803 sonde per 116 campioni.

Elemento	Risultato
Sonde iniziali	48803
Colonne iniziali	233
Colonne Detection.Pval	rimosse
Matrice dopo rimozione Detection.Pval	48803 x 116

1.2 Ricostruzione delle coppie matched

Successivamente ho distinto i campioni normali e tumorali usando il suffisso presente nel nome del campione: _N per i controlli normali e _T per i campioni tumorali. Anche se inizialmente erano presenti 58 campioni normali e 58 tumorali, dopo la ricostruzione delle coppie matched sono risultate utilizzabili 57 coppie complete, per un totale di 114 campioni. Ho quindi scelto di mantenere solo queste coppie, in modo da rendere coerente l'analisi successiva con un confronto paired.

Elemento	Risultato
Campioni Normal iniziali	58
Campioni Tumor iniziali	58
Coppie complete mantenute	57
Campioni totali dopo filtro matched	114

1.3 Trasformazione $\log_2(x+1)$

Dopo la pulizia iniziale, la matrice è stata convertita in formato numerico e trasformata con $\log_2(x + 1)$. Questa trasformazione è stata applicata per ridurre l'effetto dei valori estremi e rendere i livelli di espressione più confrontabili tra i diversi campioni. L'aggiunta di 1 è utile per evitare problemi nel caso di eventuali valori pari a zero.

1.4 Filtro basato sull'Interquartile Range (IQR)

Successivamente ho calcolato l'IQR per ciascun gene, in modo da valutare quanto ogni gene variasse tra i campioni. I geni con IQR molto basso sono poco informativi, perché presentano valori di espressione quasi costanti e difficilmente risultano utili per distinguere campioni normali e tumorali.

Osservando il grafico della distribuzione IQR, ho scelto come soglia il 10° percentile, pari a 0.2247. La linea rossa nel grafico indica questa soglia. Dopo il filtraggio sono rimasti 43922 geni e 114 campioni, mentre 4881 geni sono stati rimossi perché caratterizzati da bassa variabilità.

Distribuzione IQR




Figura 1. Distribuzione dei valori IQR dopo trasformazione log2. La linea rossa indica la soglia del 10° percentile (IQR = 0.2247).

Fase	Numero geni	Numero campioni
Prima del filtro IQR	48803	114
Dopo il filtro IQR	43922	114
Geni rimossi	4881	-

1.5 Export dei file ottenuti

Al termine della pre-elaborazione sono stati esportati due file: la matrice di espressione log2 filtrata e un file metadata contenente per ogni campione il nome, l'identificativo del paziente e il gruppo biologico. La matrice finale contiene 43922 geni e 114 campioni matched, pronta per la fase successiva di analisi differenziale paired.

File esportato	Contenuto
GSE32863_expr_log2_IQRfiltered.txt	Matrice di espressione log2 filtrata
GSE32863_metadata_matched.txt	Informazioni su campione, paziente e gruppo

Codice R utilizzato

```
# 0. CARTELLE DI LAVORO
dirData <- "data"
dirResults <- "results"

if (!dir.exists(dirData)) {
  dir.create(dirData)
}

if (!dir.exists(dirResults)) {
  dir.create(dirResults)
}

# 1. DOWNLOAD E IMPORTAZIONE DEI DATI DA GEO

library(GEOquery)
series <- "GSE32863"
getGEOSuppFiles(
  GEO = series,
  baseDir = dirData
)
```

```

file_expr <- list.files(
  path = file.path(dirData, series),
  pattern = "non-normalized.*\\.txt\\.gz$",
  full.names = TRUE,
  recursive = TRUE
)

expr <- read.delim(
  file_expr[1],
  header = TRUE,
  sep = "\t",
  stringsAsFactors = FALSE
)

dim(expr)
head(expr[, 1:10])
colnames(expr)[1:10]

# Rimozione colonne Detection.Pval
gene_ids <- expr$ID_REF
expr_values <- expr[, !grepl("Detection", colnames(expr))]
rownames(expr_values) <- expr_values$ID_REF
expr_values$ID_REF <- NULL

dim(expr_values)

# Creazione gruppi Normal/Tumor
sample_names <- colnames(expr_values)
group <- ifelse(grepl("_T$", sample_names), "Tumor", "Normal")
group <- factor(group, levels = c("Normal", "Tumor"))
table(group)

# Ricostruzione coppie matched
patient_id <- gsub("_N|T$", "", sample_names)
pair_table <- table(patient_id, group)
complete_pairs <- rownames(pair_table)[
  pair_table[, "Normal"] == 1 & pair_table[, "Tumor"] == 1
]

keep_samples <- patient_id %in% complete_pairs
expr_matched <- expr_values[, keep_samples]
group_matched <- group[keep_samples]
patient_matched <- patient_id[keep_samples]

table(group_matched)
length(unique(patient_matched))

# Matrice numerica e trasformazione log2
expr_matrix <- as.matrix(expr_matched)
mode(expr_matrix) <- "numeric"
expr_log2 <- log2(expr_matrix + 1)

# Calcolo IQR e soglia al 10° percentile
iqr_values <- apply(expr_log2, 1, IQR)
iqr_threshold <- quantile(iqr_values, 0.10)

hist(iqr_values, breaks = 50, main = "Distribuzione IQR",
  xlab = "IQR", col = "gray")
abline(v = iqr_threshold, col = "red", lwd = 2)

# Filtraggio IQR
expr_filtered <- expr_log2[iqr_values > iqr_threshold, ]
dim(expr_log2)
dim(expr_filtered)

# Export
write.table(expr_filtered,
  file = file.path(dirResults, "GSE32863_expr_log2_IQRfiltered.txt"),
  sep = "\t", quote = FALSE, col.names = NA)

metadata <- data.frame(
  Sample = colnames(expr_filtered),
  Patient = patient_matched,
  Group = group_matched
)
write.table(metadata,
  file = file.path(dirResults, "GSE32863_metadata_matched.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)

```

Sezione 2 - Filtraggio e analisi differenziale

Obiettivo della fase

In questa fase ho confrontato i campioni tumorali con i rispettivi controlli normali matched, partendo dalla matrice già trasformata in log2 e filtrata tramite IQR. L'obiettivo era individuare i geni che mostravano una variazione di espressione sufficientemente grande e statisticamente significativa tra i due gruppi.

2.1 Preparazione del confronto paired

Prima di calcolare i test statistici ho separato i campioni Normal e Tumor usando i metadata e li ho ordinati in base all'identificativo del paziente. Questo passaggio era necessario perché il dataset è composto da campioni appaiati: ogni tessuto tumorale deve essere confrontato con il corrispondente tessuto normale dello stesso paziente.

Ho inserito un controllo per verificare che le coppie Tumor/Normal fossero correttamente allineate in base all'identificativo del paziente. Dopo questa verifica sono state ottenute due matrici, una per i campioni normali e una per i campioni tumorali, entrambe con 43922 geni e 57 campioni.

Elemento	Risultato
Coppie matched utilizzate	57
Campioni Normal	57
Campioni Tumor	57
Geni analizzati dopo filtro IQR	43922
Controllo allineamento coppie	TRUE

2.2 Calcolo del logFC e scelta del test statistico

Poiché i dati erano già in scala logaritmica base 2, il fold-change non è stato calcolato come rapporto diretto tra le medie, ma come differenza tra la media dei campioni tumorali e la media dei campioni normali.

$$\text{logFC} = \text{media}(\text{Tumor}) - \text{media}(\text{Normal})$$

Un logFC positivo indica una maggiore espressione nel tumore, mentre un logFC negativo indica una minore espressione nel tumore rispetto al controllo normale. Dato che il confronto è paired e sono disponibili 57 coppie, ho usato un t-test di Student paired per ciascun gene. Poiché il numero di coppie è superiore a 30, ho considerato ragionevole applicare un test parametrico.

2.3 Correzione FDR e soglie utilizzate

Per ogni gene è stato calcolato un p-value. Poiché l'analisi viene eseguita contemporaneamente su migliaia di geni, i p-value sono stati corretti con il metodo False Discovery Rate (FDR), così da ridurre il rischio di falsi positivi.

Per selezionare i geni differenzialmente espressi ho usato due criteri: una soglia biologica sul fold-change e una soglia statistica sul p-value aggiustato. Ho scelto un fold-change minimo pari a 2, che in scala log2 corrisponde a $|\text{logFC}| \geq 1$, e una soglia di significatività pari a 0.05.

Scelta metodologica	Motivazione
t-test paired	Usato perché i campioni Tumor e Normal sono appaiati per paziente
FDR	Usato per correggere i p-value in presenza di migliaia di test
$ \text{logFC} \geq 1$	Corrisponde ad almeno un raddoppio o dimezzamento dell'espressione
p-value aggiustato ≤ 0.05	Soglia scelta per la significatività statistica

2.4 Risultati del filtraggio

Applicando entrambe le soglie sono stati identificati 1760 geni differenzialmente espressi. Di questi, 418 risultano up-regulated e 1342 down-regulated nei campioni tumorali rispetto ai controlli normali matched. I valori di logFC osservati variano da circa -4.94 a 3.37.

Risultato	Valore
Geni totali testati	43922
DEG totali	1760
Geni UP-regulated	418
Geni DOWN-regulated	1342
Range logFC	-4.94 / 3.37

Le prime righe della tabella ordinata per p-value aggiustato mostrano geni con forte down-regulation:

Gene	p-value aggiustato	logFC	Direzione
ILMN_2118129	2.48e-30	-4.10	DOWN
ILMN_1773006	2.83e-30	-3.91	DOWN
ILMN_1743445	3.89e-29	-3.99	DOWN
ILMN_1732158	2.05e-28	-3.23	DOWN
ILMN_1726210	6.63e-28	-3.29	DOWN

2.5 Volcano plot

Il volcano plot riassume visivamente i risultati dell'analisi differenziale. Sull'asse X è riportato il log2 fold-change, mentre sull'asse Y è riportato $-\log_{10}$ del p-value aggiustato. I geni in rosso sono up-regulated, quelli in blu sono down-regulated e quelli in grigio non superano le soglie impostate.




Figura 2. Volcano plot dell'analisi differenziale paired Tumor vs Normal. I geni rossi sono up-regulated, i geni blu sono down-regulated e i geni grigi non risultano significativi secondo le soglie scelte.

2.6 File esportati

Al termine della fase sono stati salvati due file: una tabella completa con tutti i geni testati e una tabella filtrata contenente soltanto i geni differenzialmente espressi. La tabella filtrata è stata poi usata nelle analisi successive.

File esportato	Contenuto
GSE32863_all_genes_results.txt	Risultati completi per tutti i geni testati
GSE32863_DEG_filtered.txt	Solo geni differenzialmente espressi

Codice R essenziale

```
# Ordinamento delle coppie matched
metadata_normal <- metadata[metadata$Group == "Normal", ]
metadata_tumor <- metadata[metadata$Group == "Tumor", ]

metadata_normal <- metadata_normal[order(metadata_normal$Patient), ]
metadata_tumor <- metadata_tumor[order(metadata_tumor$Patient), ]

all(metadata_normal$Patient == metadata_tumor$Patient)

dataN <- expr_filtered[, metadata_normal$Sample]
dataT <- expr_filtered[, metadata_tumor$Sample]

# Calcolo log Fold Change
logFC <- rowMeans(dataT) - rowMeans(dataN)

# Calcolo p-value con t-test paired
pval <- numeric(nrow(expr_filtered))
for (i in 1:nrow(expr_filtered)) {
  pval[i] <- tryCatch(
    t.test(as.numeric(dataT[i, ]),
           as.numeric(dataN[i, ]),
           paired = TRUE)$p.value,
    error = function(e) NA
  )
}

# Correzione FDR
pval_adj <- p.adjust(pval, method = "fdr")

# Tabella risultati
results <- data.frame(
  Gene = rownames(expr_filtered),
  pvalue = pval,
  pval_adj = pval_adj,
  logFC = logFC
)
results$direction <- ifelse(results$logFC > 0, "UP", "DOWN")
results <- results[order(results$pval_adj), ]

# Soglie
fc_threshold <- 2
logFC_threshold <- log2(fc_threshold)
alpha <- 0.05

# Filtraggio DEG
deg <- results[
  abs(results$logFC) >= logFC_threshold &
  results$pval_adj <= alpha,
]

dim(deg)
table(deg$direction)

# Volcano plot
volcano_color <- rep("gray", nrow(results))
volcano_color[results$logFC >= logFC_threshold & results$pval_adj <= alpha] <- "red"
volcano_color[results$logFC <= -logFC_threshold & results$pval_adj <= alpha] <- "blue"

negLogFDR <- -log10(results$pval_adj)
plot(results$logFC, negLogFDR, pch = 20, col = volcano_color,
     main = "Volcano Plot", xlab = "log2 Fold Change",
     ylab = "-log10 adjusted p-value")
abline(v = c(-logFC_threshold, logFC_threshold), col = "blue", lty = 2, lwd = 2)
abline(h = -log10(alpha), col = "red", lty = 2, lwd = 2)
legend("topright", legend = c("UP", "DOWN", "Not significant"),
     col = c("red", "blue", "gray"), pch = 20)

# Export risultati
write.table(results,
  file = file.path(dirResults, "GSE32863_all_genes_results.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)

write.table(deg,
  file = file.path(dirResults, "GSE32863_DEG_filtered.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)
```

Sezione 3 - Grafici e ulteriori analisi dei dati

Obiettivo della fase

In questa fase ho utilizzato i geni differenzialmente espressi ottenuti nella fase precedente per produrre alcuni grafici esplorativi. L'obiettivo era verificare se i DEG identificati fossero in grado di distinguere visivamente i campioni tumorali dai campioni normali matched.

Per prima cosa ho selezionato il gene più up-regulated e il gene più down-regulated, in modo da mostrare due esempi estremi di variazione di espressione. Successivamente ho costruito una heatmap utilizzando i top 50 geni differenzialmente espressi, scelti tra quelli più significativi, così da ottenere un grafico leggibile e interpretabile. Infine, ho eseguito una PCA sui DEG per valutare se i campioni Normal e Tumor si separassero anche in uno spazio a dimensione ridotta.

Elemento	Risultato
DEG totali	1760
UP-regulated	418
DOWN-regulated	1342
Top UP-regulated	ILMN_2343774
Top DOWN-regulated	ILMN_1784493

3.1 Scelte grafiche e motivazione

Analisi	Motivazione
Boxplot top up/down	Mostrare due esempi estremi di variazione di espressione tra Normal e Tumor
Heatmap top 50 DEG	Rendere il grafico leggibile usando i geni più significativi invece di tutti i 1760 DEG
scale = "row"	Confrontare il comportamento relativo di ciascun gene tra i campioni
PCA sui DEG	Verificare se i profili dei DEG separano i campioni in uno spazio a dimensione ridotta

3.2 Boxplot dei geni selezionati

I boxplot sono stati costruiti per visualizzare la distribuzione dell'espressione dei due geni più rappresentativi tra i DEG. Il gene ILMN_2343774 è stato scelto perché ha il logFC massimo, mentre ILMN_1784493 è stato scelto perché ha il logFC minimo. Questi due grafici permettono di verificare visivamente che i due geni mostrino un comportamento diverso nei campioni Normal e Tumor.




Figura 3. Boxplot del gene più up-regulated (ILMN_2343774). Il gruppo Tumor mostra valori di espressione più elevati rispetto al gruppo Normal.




Figura 4. Boxplot del gene più down-regulated (ILMN_1784493). Il gruppo Normal mostra valori di espressione più elevati rispetto al gruppo Tumor.

3.3 Heatmap dei top 50 DEG

La heatmap è stata costruita utilizzando i top 50 geni differenzialmente espressi ordinati per significatività. Ho scelto di non rappresentare tutti i 1760 DEG perché il grafico sarebbe risultato troppo denso e meno leggibile. I valori sono stati scalati per riga, così da evidenziare il comportamento relativo di ciascun gene tra i campioni, indipendentemente dal livello assoluto di espressione.

Il clustering dei campioni mostra una separazione chiara tra Normal e Tumor. Questo risultato è coerente con l'analisi differenziale e suggerisce che i geni selezionati descrivano differenze trascrittomiche rilevanti tra i due gruppi.



Figura 5. Heatmap dei top 50 geni differenzialmente espressi. La barra superiore indica il gruppo di appartenenza dei campioni.

3.4 Analisi delle Componenti Principali (PCA)

La PCA è stata calcolata usando tutti i 1760 geni differenzialmente espressi. L'obiettivo non era selezionare nuovi geni, ma verificare se i DEG già identificati fossero sufficienti a separare i campioni in base al gruppo biologico.

La prima componente principale spiega il 57.51% della varianza, mentre la seconda componente principale spiega il 9.36%. Complessivamente, PC1 e PC2 spiegano circa il 66.87% della variabilità totale. Nel grafico si osserva una separazione netta tra Normal e Tumor soprattutto lungo PC1.

Componente	Varianza spiegata
PC1	57.51%
PC2	9.36%
PC1 + PC2	66.87%




Figura 6. PCA dei geni differenzialmente espressi. I campioni Normal e Tumor formano due gruppi distinti, separati principalmente lungo PC1.

3.5 Interpretazione complessiva

Nel complesso, i grafici supportano visivamente i risultati ottenuti nella fase di analisi differenziale. I boxplot mostrano due esempi chiari di geni con espressione diversa tra i gruppi, la heatmap evidenzia pattern coerenti con la distinzione tra tessuto tumorale e tessuto normale e la PCA conferma che i profili dei DEG permettono di separare chiaramente i campioni Normal e Tumor.

Codice R utilizzato

```
# Selezione del gene piu up-regulated e piu down-regulated
top_up <- deg$Gene[which.max(deg$logFC)]
top_down <- deg$Gene[which.min(deg$logFC)]

top_up
top_down

# Boxplot gene up-regulated
up_values <- data.frame(
  Expression = as.numeric(expr_filtered[top_up, ]),
  Group = metadata$Group,
  Patient = metadata$Patient
)
boxplot(Expression ~ Group, data = up_values,
  col = c("lightblue", "salmon"),
  main = paste("Top Up-regulated Gene:", top_up),
  xlab = "Group", ylab = "Expression")
stripchart(Expression ~ Group, data = up_values,
  vertical = TRUE, method = "jitter",
  pch = 20, col = "black", add = TRUE)

# Boxplot gene down-regulated
down_values <- data.frame(
  Expression = as.numeric(expr_filtered[top_down, ]),
  Group = metadata$Group,
  Patient = metadata$Patient
)
boxplot(Expression ~ Group, data = down_values,
  col = c("lightblue", "salmon"),
  main = paste("Top Down-regulated Gene:", top_down),
```

```

      xlab = "Group", ylab = "Expression")
stripchart(Expression ~ Group, data = down_values,
            vertical = TRUE, method = "jitter",
            pch = 20, col = "black", add = TRUE)

# Heatmap dei top 50 DEG
library(pheatmap)
top_n <- 50
top_deg_genes <- deg$Gene[1:top_n]
heatmap_matrix <- expr_filtered[top_deg_genes, ]
annotation_col <- data.frame(Group = metadata$Group)
rownames(annotation_col) <- metadata$Sample
pheatmap(heatmap_matrix, scale = "row",
          show_rownames = TRUE, show_colnames = FALSE,
          annotation_col = annotation_col,
          main = paste("Heatmap of Top", top_n, "Differentially Expressed Genes"))

# PCA sui DEG
pca_matrix <- t(expr_filtered[deg$Gene, ])
pca_res <- prcomp(pca_matrix, scale. = TRUE)
summary(pca_res)

pca_df <- data.frame(
  PC1 = pca_res$x[, 1],
  PC2 = pca_res$x[, 2],
  Group = metadata$Group,
  Sample = metadata$Sample
)
plot(pca_df$PC1, pca_df$PC2,
     col = ifelse(pca_df$Group == "Tumor", "red", "blue"),
     pch = 19, xlab = "PC1", ylab = "PC2",
     main = "PCA of Differentially Expressed Genes")
legend("topright", legend = c("Normal", "Tumor"),
     col = c("blue", "red"), pch = 19)

```

Sezione 4 - Esportazione dei risultati

Obiettivo della fase

In questa fase ho salvato in un file di testo la lista finale dei geni differenzialmente espressi ottenuti dall'analisi. L'obiettivo era produrre una tabella semplice da controllare e riutilizzare nelle fasi successive, in particolare per l'annotazione dei geni e per l'enrichment analysis.

4.1 Costruzione della tabella finale

La tabella finale è stata costruita a partire dall'oggetto `deg`, cioè dall'elenco dei geni che hanno superato le soglie definite nella Fase 2: `|logFC| >= 1` e `p-value aggiustato <= 0.05`. Ho mantenuto solo le colonne più utili per la lettura dei risultati: identificativo del gene, p-value aggiustato, logFC e direzione della regolazione.

Elemento	Risultato
Nome file	Differentially_Expressed_Genes.txt
Numero di geni esportati	1760
Numero di colonne	4
Geni Upregulated	418
Geni Downregulated	1342
Controllo file.exists()	TRUE

4.2 Descrizione delle colonne esportate

Colonna	Descrizione
Gene	Identificativo della sonda/gene differenzialmente espresso
adj.P.Val	p-value corretto con metodo FDR
logFC	Differenza media di espressione Tumor - Normal in scala log2
Regulation	Indicazione Upregulated o Downregulated in base al segno del logFC

4.3 Motivazione dell'export

Ho scelto di esportare i risultati in formato .txt separato da tabulazioni perché è un formato semplice, leggibile sia in R sia in altri programmi, e può essere riutilizzato facilmente nelle analisi successive. Inoltre, salvare una tabella finale permette di documentare in modo chiaro quali geni sono stati effettivamente considerati differenzialmente espressi.

Scelta	Motivazione
Formato .txt	Formato semplice e facilmente riutilizzabile
sep = "\t"	Produce un file tab-delimited ordinato in colonne
quote = FALSE	Evita virgolette non necessarie nel file finale
row.names = FALSE	Evita una colonna aggiuntiva non richiesta

4.4 Prime righe del file finale

Le prime righe del file mostrano i geni più significativi ordinati in base al p-value aggiustato. In questo caso i primi geni risultano downregulated nei campioni tumorali rispetto ai controlli normali matched.

Gene	adj.P.Val	logFC	Regulation
ILMN_2118129	2.481e-30	-4.100	Downregulated
ILMN_1773006	2.834e-30	-3.910	Downregulated
ILMN_1743445	3.888e-29	-3.991	Downregulated
ILMN_1732158	2.048e-28	-3.226	Downregulated
ILMN_1726210	6.628e-28	-3.294	Downregulated
ILMN_1762713	1.874e-26	-4.360	Downregulated

4.5 Interpretazione

Il file finale contiene 1760 geni differenzialmente espressi: 418 upregulated e 1342 downregulated. Questa tabella rappresenta il risultato finale della fase statistica del progetto e costituisce il punto di partenza per le analisi biologiche successive. In particolare, l'elenco dei geni esportati può essere usato per convertire gli identificativi delle sonde in simboli genici e per eseguire l'enrichment analysis.

Codice R utilizzato

```
# =====  
# 5. ESPORTAZIONE DEI RISULTATI  
# =====  
  
final_results <- data.frame(  
  Gene = deg$Gene,  
  adj.P.Val = deg$pvadj,  
  logFC = deg$logFC,  
  Regulation = ifelse(  
    deg$logFC > 0,  
    "Upregulated",  
    "Downregulated"  
  )  
)  
  
final_results <- final_results[order(final_results$adj.P.Val), ]  
  
head(final_results)  
dim(final_results)  
table(final_results$Regulation)  
  
write.table(  
  final_results,  
  file = file.path(dirResults, "Differentially_Expressed_Genes.txt"),  
  sep = "\t",  
  quote = FALSE,  
  row.names = FALSE  
)  
  
file.exists(  
  file.path(dirResults, "Differentially_Expressed_Genes.txt")  
)
```

Sezione 5 - Analisi di arricchimento funzionale

Obiettivo della fase

Dopo aver ottenuto la lista dei geni differenzialmente espressi, ho eseguito un'analisi di arricchimento funzionale con EnrichR. L'obiettivo non era più identificare singoli geni, ma capire se l'elenco dei DEG fosse associato a processi biologici o pathway specifici.

Prima dell'analisi è stato necessario convertire gli identificativi delle sonde Illumina in simboli genici, perché EnrichR lavora principalmente con gene symbols.

5.1 Preparazione della lista genica

La lista di partenza era costituita dai 1760 geni differenzialmente espressi ottenuti nella fase precedente. Poiché questi geni erano identificati come sonde Illumina, ho usato il pacchetto illuminaHumanv3.db per convertirli in simboli genici. Dopo aver rimosso valori non annotati e duplicati, sono rimasti 1451 gene symbols unici.

Elemento	Risultato
Geni differenzialmente espressi iniziali	1760
Database di annotazione	illuminaHumanv3.db
Gene symbols unici ottenuti	1451
Esempi di gene symbols	ITLN2, FABP4, FAM107A, FMO2, GPIHBP1, MCEMP1

Durante la conversione è comparso il messaggio relativo al mapping 1:many. Questo non è stato considerato un errore, perché alcune sonde possono essere associate a più annotazioni. In questo caso è stata mantenuta la prima associazione disponibile tramite `multiVals = "first"`.

5.2 Database utilizzati in EnrichR

L'analisi è stata eseguita su tre database, scelti per ottenere una visione complementare dei risultati: processi biologici, pathway metabolici/signaling e pathway Reactome.

Database	Scopo
GO_Biological_Process_2023	Processi biologici arricchiti
KEGG_2021_Human	Pathway biologici e cellulari
Reactome_2022	Pathway funzionali curati in Reactome

5.3 Risultati GO Biological Process

I risultati GO mostrano un arricchimento di processi legati alla risposta a citochine, angiogenesi, proliferazione cellulare, infiammazione e motilità cellulare. Questi processi sono coerenti con un confronto tra tessuto tumorale e tessuto normale.

Termine GO	Overlap	Adjusted p-value
Cellular Response To Cytokine Stimulus	72/308	1.11e-15
Regulation Of Angiogenesis	55/205	1.42e-14
Regulation Of Cell Population Proliferation	118/766	4.05e-12
Inflammatory Response	52/236	2.97e-10
Positive Regulation Of Angiogenesis	35/119	2.97e-10
Positive Regulation Of Cell Motility	48/221	3.15e-09

5.4 Risultati KEGG

Nei risultati KEGG compaiono pathway associati a risposta immunitaria, fagocitosi, complemento e coagulazione. Alcuni pathway hanno nomi legati a infezioni, ma in questo contesto non indicano necessariamente un'infezione nei campioni: compaiono perché condividono geni coinvolti in infiammazione, HLA, complemento e immunità.

Pathway KEGG	Overlap	Adjusted p-value
Phagosome	40/152	1.34e-10
Leishmaniasis	27/77	2.63e-10
Complement and coagulation cascades	28/85	3.94e-10
Osteoclast differentiation	33/127	4.73e-09
Staphylococcus aureus infection	28/95	4.73e-09
Hematopoietic cell lineage	27/99	5.87e-08

5.5 Risultati Reactome

I risultati Reactome confermano il coinvolgimento del sistema immunitario, dell'immunità innata, delle interazioni vascolari, della degranolazione dei neutrofili e della matrice extracellulare. Questi pathway descrivono bene componenti del microambiente tumorale.

Pathway Reactome	Overlap	Adjusted p-value
Immune System	241/1943	1.55e-14
Innate Immune System	146/1035	1.92e-12
Cell Surface Interactions At Vascular Wall	37/134	3.21e-10
Neutrophil Degranulation	79/468	4.52e-10
Extracellular Matrix Organization	55/291	1.26e-08
Interleukin-4 And Interleukin-13 Signaling	29/107	7.96e-08

5.6 Interpretazione complessiva

Nel complesso, l'enrichment analysis suggerisce che i geni differenzialmente espressi siano associati soprattutto a risposta immunitaria, infiammazione, angiogenesi, complemento/coagulazione e rimodellamento della matrice extracellulare. Questi risultati sono coerenti con l'idea che il tessuto tumorale presenti alterazioni non solo nei singoli geni, ma anche in interi processi biologici legati al microambiente tumorale.

Per questo motivo, l'analisi di arricchimento è utile come passaggio successivo all'analisi differenziale: permette di passare da una lista di geni a una lettura biologica più generale dei risultati.

5.7 File esportati

File esportato	Contenuto
GO_results_GSE32863.txt	Risultati GO Biological Process
KEGG_results_GSE32863.txt	Risultati KEGG
Reactome_results_GSE32863.txt	Risultati Reactome

Codice R utilizzato

```
# =====  
# 6. ANALISI DI ARRICCHIMENTO FUNZIONALE  
# =====  
  
library(AnnotationDbi)  
library(illuminaHumanv3.db)  
library(enrichR)  
  
# Conversione Probe ID -> Gene Symbol  
probe_ids <- final_results$Gene  
  
gene_symbols <- mapIds(  
  illuminaHumanv3.db,  
  keys = probe_ids,  
  column = "SYMBOL",  
  keytype = "PROBEID",  
  multiVals = "first"  
)  
  
gene_symbols <- na.omit(gene_symbols)  
gene_symbols <- unique(gene_symbols)  
  
length(gene_symbols)  
head(gene_symbols)  
  
# Database EnrichR  
dbs <- listEnrichrDbs()  
head(dbs)  
  
databases <- c(  
  "GO_Biological_Process_2023",  
  "KEGG_2021_Human",  
  "Reactome_2022"  
)  
  
# Enrichment analysis  
enrich_results <- enrichr(gene_symbols, databases)  
  
GO_results <- enrich_results[["GO_Biological_Process_2023"]]  
KEGG_results <- enrich_results[["KEGG_2021_Human"]]  
Reactome_results <- enrich_results[["Reactome_2022"]]  
  
head(GO_results)
```

```
head(KEGG_results)
head(Reactome_results)

# Export risultati
write.table(GO_results,
  file = file.path(dirResults, "GO_results_GSE32863.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)

write.table(KEGG_results,
  file = file.path(dirResults, "KEGG_results_GSE32863.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)

write.table(Reactome_results,
  file = file.path(dirResults, "Reactome_results_GSE32863.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)
```

Sezione 6 - Analisi aggiuntiva e ricerca bibliografica

Obiettivo della fase

In questa fase ho approfondito i risultati ottenuti nelle analisi precedenti, collegando i pathway emersi dall'enrichment analysis con informazioni provenienti da banche dati biologiche e da letteratura scientifica. L'obiettivo era passare da una lista di geni e pathway a un'interpretazione biologica più generale del confronto tra tessuto tumorale e tessuto normale matched.

6.1 Fonti consultate

Per interpretare i risultati ho considerato sia le banche dati utilizzate nell'analisi computazionale sia la letteratura scientifica sul carcinoma polmonare. In particolare, i risultati di EnrichR sono stati confrontati con informazioni relative al microambiente tumorale, alla risposta immunitaria, all'angiogenesi, al complemento/coagulazione e al rimodellamento della matrice extracellulare.

Fonte	Uso nella sezione
GEO / GSE32863	Dataset e origine dei campioni analizzati
GO Biological Process	Processi biologici arricchiti nei DEG
KEGG	Pathway funzionali e cellulari
Reactome	Pathway immunitari, vascolari e della matrice extracellulare
PubMed / articoli scientifici	Supporto bibliografico per interpretare i risultati

6.2 Sintesi dei risultati biologici principali

L'enrichment analysis ha evidenziato soprattutto processi collegati a risposta a citochine, infiammazione, angiogenesi, risposta immunitaria innata, complemento/coagulazione e organizzazione della matrice extracellulare. Questi risultati sono coerenti con il fatto che un tumore non è formato solo da cellule tumorali, ma anche da cellule immunitarie, cellule stromali, vasi sanguigni e matrice extracellulare.

Tema emerso	Evidenza nei risultati	Interpretazione
Citochine e infiammazione	GO: Cellular Response To Cytokine Stimulus, Inflammatory Response	Presenza di segnali infiammatori e immunitari alterati
Angiogenesi	GO: Regulation/Positive Regulation Of Angiogenesis	Possibile coinvolgimento di processi vascolari e crescita tumorale
Sistema immunitario	Reactome: Immune System, Innate Immune System, Neutrophil Degranulation	Ruolo del microambiente immunitario tumorale
Complemento e coagulazione	KEGG: Complement and coagulation cascades	Possibile interazione tra infiammazione, immunità e segnali vascolari
Matrice extracellulare	Reactome: Extracellular Matrix Organization	Rimodellamento del tessuto e possibile invasività

6.3 Risposta immunitaria, citochine e infiammazione

Il termine GO più significativo è risultato Cellular Response To Cytokine Stimulus, seguito da processi collegati a infiammazione e risposta immunitaria. Tra i geni coinvolti compaiono, ad esempio, CXCL8, IL1B, IL6, CCL2, CCL3, CCL4, CCL5, STAT1 e diversi geni HLA. Questo suggerisce che il confronto Tumor vs Normal non evidenzia solo cambiamenti nelle cellule epiteliali, ma anche una componente legata al microambiente immunitario.

La letteratura sul carcinoma polmonare descrive infatti l'infiammazione come una componente importante del microambiente tumorale. Citochine come IL-6, IL-1 e TNF possono partecipare al mantenimento di un ambiente infiammatorio, alla progressione tumorale e alla modulazione della risposta immunitaria.

6.4 Angiogenesi e segnali vascolari

Un altro risultato rilevante è l'arricchimento dei processi di angiogenesi. Nei risultati GO compaiono Regulation Of Angiogenesis e Positive Regulation Of Angiogenesis, con geni come VEGFC, VEGFD, TEK, IL6, CXCL8 e CDH5. L'angiogenesi è un processo importante nei tumori solidi, perché la formazione di nuovi vasi può sostenere crescita, invasione e diffusione tumorale.

Nel contesto del carcinoma polmonare, la presenza di pathway angiogenici è quindi coerente con una possibile riorganizzazione del compartimento vascolare e del microambiente tumorale.

6.5 Complemento, coagulazione e immunità innata

Nei risultati KEGG è emerso il pathway Complement and coagulation cascades, mentre Reactome ha evidenziato Immune System, Innate Immune System e Neutrophil Degranulation. Tra i geni presenti nei pathway compaiono C1QA, C1QB, C1QC, C3, C5AR1, C6, C7, VWF, F10 e F12.

Questi risultati possono essere interpretati come un segnale di attivazione o alterazione di meccanismi immunitari innati e vascolari. Il complemento e la coagulazione sono sistemi legati alla risposta immunitaria e all'omeostasi tissutale, ma nel tumore possono anche contribuire alla regolazione del microambiente tumorale.

6.6 Matrice extracellulare, motilità e rimodellamento tissutale

Reactome ha evidenziato anche Extracellular Matrix Organization, mentre nei risultati GO compare Positive Regulation Of Cell Motility. Nei geni associati a questi processi sono presenti collagene, metalloproteasi e molecole di adesione, come COL1A1, COL1A2, COL3A1, MMP9, ITGA5 e CD44.

Il rimodellamento della matrice extracellulare è un aspetto importante della progressione tumorale, perché può modificare la struttura del tessuto, favorire interazioni tra cellule tumorali e microambiente e contribuire a processi di invasione e migrazione cellulare.

6.7 Interpretazione complessiva

Nel complesso, i risultati suggeriscono che i geni differenzialmente espressi nel dataset GSE32863 non riflettano soltanto variazioni isolate di singoli geni, ma descrivano un cambiamento più ampio del tessuto tumorale rispetto al tessuto normale. I processi maggiormente rappresentati riguardano immunità, infiammazione, angiogenesi, complemento/coagulazione e matrice extracellulare.

Questa interpretazione è coerente con la biologia del carcinoma polmonare, in cui il microambiente tumorale svolge un ruolo importante nella progressione della malattia. Tuttavia, è importante sottolineare che l'enrichment analysis non dimostra da sola l'attivazione funzionale di un pathway: fornisce un'indicazione statistica utile per formulare ipotesi biologiche da approfondire.

6.8 Conclusione della sezione

L'analisi aggiuntiva ha permesso di interpretare i 1760 DEG in modo più biologico. I pathway arricchiti indicano che il confronto tra adenocarcinoma polmonare e tessuto normale matched coinvolge soprattutto processi immunitari, infiammatori, vascolari e stromali. Questi risultati forniscono una spiegazione biologica coerente con le analisi precedenti e completano il percorso che va dal dato grezzo alla sua interpretazione funzionale.