

Università	Università San Raffaele
Corso	LM-32 - Ingegneria Informatica e dell'Intelligenza Artificiale Applicata
Esame	Esame di Elementi di Bioinformatica
Professoressa	Giulia Fiscon
Studente	Vincenzo Crivella

Analisi di geni differenzialmente espressi - Dataset GSE32763

Il progetto ha lo scopo di analizzare il dataset GSE32863, relativo all'adenocarcinoma polmonare, per individuare geni differenzialmente espressi tra campioni tumorali e campioni normali matched. Il progetto prevede i seguenti step: la pre-elaborazione dei dati, il filtraggio dei geni poco variabili, l'identificazione dei DEG tramite confronto paired, la visualizzazione grafica dei risultati e l'analisi di arricchimento funzionale con EnrichR, al fine di interpretare i risultati anche dal punto di vista biologico.

Sezione 1 - Pre-elaborazione dei dati

Obiettivo della fase

Questa prima parte del progetto ha lo scopo di importare il dataset di espressione genica, rimuovere le colonne non necessarie, ricostruire le coppie matched Tumor/Normal e preparare una matrice numerica adatta alla successiva analisi differenziale.

1.1 Importazione e pulizia iniziale

In questa prima fase è stato importato il dataset GSE32863 in RStudio e controllata la struttura iniziale del file. Il dataset conteneva 48803 sonde e 233 colonne, perché ai valori di espressione erano alternate anche colonne relative ai Detection P-value. Poiché l'analisi differenziale richiede soltanto i valori di espressione, sono state rimosse queste colonne ed è stata mantenuta una matrice di 48803 sonde per 116 campioni.

Elemento	Risultato
Sonde iniziali	48803
Colonne iniziali	233
Colonne Detection.Pval	rimosse
Matrice dopo rimozione Detection.Pval	48803 x 116

1.2 Ricostruzione delle coppie matched

Successivamente sono stati distinti i campioni normali e tumorali usando il suffisso presente nel nome del campione: _N per i controlli normali e _T per i campioni tumorali. Inizialmente risultavano presenti 58 campioni normali e 58 tumorali; a seguito della ricostruzione delle coppie matched sono risultate utilizzabili 57 coppie complete, per un totale di 114 campioni; per questo motivo si è optato per il mantenimento di queste sole coppie, così da rendere coerente l'analisi successiva con un confronto paired.

Elemento	Risultato
Campioni Normal iniziali	58
Campioni Tumor iniziali	58
Coppie complete mantenute	57
Campioni totali dopo filtro matched	114

1.3 Trasformazione $\log_2(x+1)$

Dopo la pulizia iniziale, la matrice è stata convertita in formato numerico e trasformata con $\log_2(x + 1)$. Questa trasformazione è stata applicata per ridurre l'effetto dei valori estremi e rendere i livelli di espressione più confrontabili tra i diversi campioni. L'aggiunta di 1 è utile per evitare problemi nel caso di eventuali valori pari a zero.

1.4 Filtro basato sull'Interquartile Range (IQR)

Successivamente è stato calcolato l'IQR per ciascun gene, in modo da valutare quanto ogni gene variasse tra i campioni. I geni con IQR molto basso sono poco informativi, perché presentano valori di espressione quasi costanti e difficilmente risultano utili per distinguere campioni normali e tumorali.

Osservando il grafico della distribuzione IQR, si è scelto come soglia il 10° percentile, pari a 0.2247 (indicato dalla linea rossa nel grafico sottostante). Dopo il filtraggio sono rimasti 43922 geni e 114 campioni, mentre 4881 geni sono stati rimossi perché caratterizzati da bassa variabilità.




Figura 1. Distribuzione dei valori IQR dopo trasformazione $\log_2$. La linea rossa indica la soglia del 10° percentile (IQR = 0.2247).

Fase	Numero geni	Numero campioni
Prima del filtro IQR	48803	114
Dopo il filtro IQR	43922	114
Geni rimossi	4881	-

Codice R utilizzato

```
# 0. CARTELLE DI LAVORO
dirData <- "data"
dirResults <- "results"

if (!dir.exists(dirData)) {
  dir.create(dirData)
}

if (!dir.exists(dirResults)) {
  dir.create(dirResults)
}

# 1. DOWNLOAD E IMPORTAZIONE DEI DATI DA GEO

library(GEOquery)
series <- "GSE32863"
getGEOSuppFiles(
  GEO = series,
  baseDir = dirData
)

file_expr <- list.files(
  path = file.path(dirData, series),
  pattern = "non-normalized.*\\.txt\\.gz$",
  full.names = TRUE,
  recursive = TRUE
)

expr <- read.delim(
  file_expr[1],
  header = TRUE,
  sep = "\t",
  stringsAsFactors = FALSE
)

dim(expr)
head(expr[, 1:10])
colnames(expr)[1:10]

# Rimozione colonne Detection.Pval
gene_ids <- expr$ID_REF
expr_values <- expr[, !grepl("Detection", colnames(expr))]
rownames(expr_values) <- expr_values$ID_REF
expr_values$ID_REF <- NULL

dim(expr_values)

# Creazione gruppi Normal/Tumor
sample_names <- colnames(expr_values)
group <- ifelse(grepl("_T$", sample_names), "Tumor", "Normal")
group <- factor(group, levels = c("Normal", "Tumor"))
table(group)

# Ricostruzione coppie matched
patient_id <- gsub("(N|T)$", "", sample_names)
pair_table <- table(patient_id, group)
complete_pairs <- rownames(pair_table)[
  pair_table[, "Normal"] == 1 & pair_table[, "Tumor"] == 1
]

keep_samples <- patient_id %in% complete_pairs
expr_matched <- expr_values[, keep_samples]
group_matched <- group[keep_samples]
patient_matched <- patient_id[keep_samples]

table(group_matched)
length(unique(patient_matched))

# Matrice numerica e trasformazione log2
expr_matrix <- as.matrix(expr_matched)
mode(expr_matrix) <- "numeric"
expr_log2 <- log2(expr_matrix + 1)

# Calcolo IQR e soglia al 10° percentile
iqr_values <- apply(expr_log2, 1, IQR)
iqr_threshold <- quantile(iqr_values, 0.10)

hist(iqr_values, breaks = 50, main = "Distribuzione IQR",
  xlab = "IQR", col = "gray")
abline(v = iqr_threshold, col = "red", lwd = 2)
```

```
# Filtraggio IQR
expr_filtered <- expr_log2[iqr_values > iqr_threshold, ]
dim(expr_log2)
dim(expr_filtered)

# Export
write.table(expr_filtered,
  file = file.path(dirResults, "GSE32863_expr_log2_IQRfiltered.txt"),
  sep = "\t", quote = FALSE, col.names = NA)

metadata <- data.frame(
  Sample = colnames(expr_filtered),
  Patient = patient_matched,
  Group = group_matched
)
write.table(metadata,
  file = file.path(dirResults, "GSE32863_metadata_matched.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)
```

Sezione 2 - Filtraggio e analisi differenziale

Obiettivo della fase

In questa fase è stato effettuato il confronto tra i campioni tumorali con i rispettivi controlli normali matched, partendo dalla matrice già trasformata in log2 e filtrata tramite IQR. L'obiettivo consiste nell'individuare i geni con una variazione di espressione sufficientemente grande e statisticamente significativa tra i due gruppi.

2.1 Preparazione del confronto paired

Prima di calcolare i test statistici sono stati separati i campioni Normal e Tumor usando i metadata, per poi ordinarli in base all'identificativo del paziente. Questo passaggio è necessario in quanto il dataset è composto da campioni appaiati: ogni tessuto tumorale deve essere confrontato con il corrispondente tessuto normale dello stesso paziente.

E' stato inserito un controllo per verificare che le coppie Tumor/Normal fossero correttamente allineate in base all'identificativo del paziente. A seguito di questa verifica sono state ottenute due matrici, una per i campioni normali e una per i campioni tumorali, entrambe con 43922 geni e 57 campioni.

Elemento	Risultato
Coppie matched utilizzate	57
Campioni Normal	57
Campioni Tumor	57
Geni analizzati dopo filtro IQR	43922
Controllo allineamento coppie	TRUE

2.2 Calcolo del logFC e scelta del test statistico

Poiché i dati erano già in scala logaritmica base 2, il fold-change non è stato calcolato come rapporto diretto tra le medie, ma come differenza tra la media dei campioni tumorali e la media dei campioni normali.

$$\text{logFC} = \text{media}(\text{Tumor}) - \text{media}(\text{Normal})$$

Un logFC positivo indica una maggiore espressione nel tumore, mentre un logFC negativo indica una minore espressione nel tumore rispetto al controllo normale. Considerando che il confronto è paired e sono disponibili 57 coppie, è stato usato un t-test di Student paired per ciascun gene. Poiché il numero di coppie è superiore a 30, è stato applicato un test parametrico.

2.3 Correzione FDR e soglie utilizzate

Per ogni gene è stato calcolato un p-value. Poiché l'analisi viene eseguita contemporaneamente su migliaia di geni, i p-value sono stati corretti con il metodo False Discovery Rate (FDR), così da ridurre il rischio di falsi positivi.

Per selezionare i geni differenzialmente espressi sono stati considerati due criteri: una soglia biologica sul fold-change e una soglia statistica sul p-value aggiustato. Si è optato per un fold-change minimo pari a 2, che in scala log2 corrisponde a $|\text{logFC}| \geq 1$, e una soglia di significatività pari a 0.05.

Scelta metodologica	Motivazione
t-test paired	Usato perché i campioni Tumor e Normal sono appaiati per paziente
FDR	Usato per correggere i p-value in presenza di migliaia di test
$ \text{logFC} \geq 1$	Corrisponde ad almeno un raddoppio o dimezzamento dell'espressione
p-value aggiustato ≤ 0.05	Soglia scelta per la significatività statistica

2.4 Risultati del filtraggio

Applicando entrambe le soglie sono stati identificati 1760 geni differenzialmente espressi. Di questi, 418 risultano up-regulated e 1342 down-regulated nei campioni tumorali rispetto ai controlli normali matched. I valori di logFC osservati variano da circa -4.94 a 3.37.

Risultato	Valore
Geni totali testati	43922
DEG totali	1760
Geni UP-regulated	418
Geni DOWN-regulated	1342
Range logFC	-4.94 / 3.37

Le prime righe della tabella ordinata per p-value aggiustato mostrano geni con forte down-regulation:

Gene	p-value aggiustato	logFC	Direzione
ILMN_2118129	2.48e-30	-4.10	DOWN
ILMN_1773006	2.83e-30	-3.91	DOWN
ILMN_1743445	3.89e-29	-3.99	DOWN
ILMN_1732158	2.05e-28	-3.23	DOWN
ILMN_1726210	6.63e-28	-3.29	DOWN

2.5 Volcano plot

Il volcano plot riassume visivamente i risultati dell'analisi differenziale. Sull'asse X è riportato il log2 fold-change, mentre sull'asse Y è riportato $-\log_{10}$ del p-value aggiustato. I geni in rosso sono up-regulated, quelli in blu sono down-regulated e quelli in grigio non superano le soglie impostate.




Figura 2. Volcano plot dell'analisi differenziale paired Tumor vs Normal. I geni rossi sono up-regulated, i geni blu sono down-regulated e i geni grigi non risultano significativi secondo le soglie scelte.

Codice R essenziale

```
# Ordinamento delle coppie matched
metadata_normal <- metadata[metadata$Group == "Normal", ]
metadata_tumor <- metadata[metadata$Group == "Tumor", ]

metadata_normal <- metadata_normal[order(metadata_normal$Patient), ]
metadata_tumor <- metadata_tumor[order(metadata_tumor$Patient), ]

all(metadata_normal$Patient == metadata_tumor$Patient)

dataN <- expr_filtered[, metadata_normal$Sample]
dataT <- expr_filtered[, metadata_tumor$Sample]

# Calcolo log Fold Change
logFC <- rowMeans(dataT) - rowMeans(dataN)

# Calcolo p-value con t-test paired
pval <- numeric(nrow(expr_filtered))
for (i in 1:nrow(expr_filtered)) {
  pval[i] <- tryCatch(
    t.test(as.numeric(dataT[i, ]),
           as.numeric(dataN[i, ]),
           paired = TRUE)$p.value,
    error = function(e) NA
  )
}

# Correzione FDR
pval_adj <- p.adjust(pval, method = "fdr")

# Tabella risultati
results <- data.frame(
  Gene = rownames(expr_filtered),
  pvalue = pval,
  pval_adj = pval_adj,
  logFC = logFC
)
results$direction <- ifelse(results$logFC > 0, "UP", "DOWN")
results <- results[order(results$pval_adj), ]

# Soglie
fc_threshold <- 2
logFC_threshold <- log2(fc_threshold)
alpha <- 0.05

# Filtraggio DEG
deg <- results[
  abs(results$logFC) >= logFC_threshold &
  results$pval_adj <= alpha,
]

dim(deg)
table(deg$direction)

# Volcano plot
volcano_color <- rep("gray", nrow(results))
volcano_color[results$logFC >= logFC_threshold & results$pval_adj <= alpha] <- "red"
volcano_color[results$logFC <= -logFC_threshold & results$pval_adj <= alpha] <- "blue"

negLogFDR <- -log10(results$pval_adj)
plot(results$logFC, negLogFDR, pch = 20, col = volcano_color,
     main = "Volcano Plot", xlab = "log2 Fold Change",
     ylab = "-log10 adjusted p-value")
abline(v = c(-logFC_threshold, logFC_threshold), col = "blue", lty = 2, lwd = 2)
abline(h = -log10(alpha), col = "red", lty = 2, lwd = 2)
legend("topright", legend = c("UP", "DOWN", "Not significant"),
     col = c("red", "blue", "gray"), pch = 20)

# Export risultati
write.table(results,
  file = file.path(dirResults, "GSE32863_all_genes_results.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)

write.table(deg,
  file = file.path(dirResults, "GSE32863_DEG_filtered.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)
```

Sezione 3 - Grafici e ulteriori analisi dei dati

Obiettivo della fase

In questa fase sono stati utilizzati i geni differenzialmente espressi ottenuti nella fase precedente per produrre alcuni grafici esplorativi. L'obiettivo era verificare se i DEG identificati fossero in grado di distinguere visivamente i campioni tumorali dai campioni normali matched.

Per prima cosa è stato selezionato il gene più up-regulated e il gene più down-regulated, in modo da mostrare due esempi estremi di variazione di espressione. Successivamente è stata costruita una heatmap utilizzando i top 50 geni differenzialmente espressi, scelti tra quelli più significativi, così da ottenere un grafico leggibile e interpretabile. Infine, è stata eseguita una PCA sui DEG per valutare se i campioni Normal e Tumor si separassero anche in uno spazio a dimensione ridotta.

Elemento	Risultato
DEG totali	1760
UP-regulated	418
DOWN-regulated	1342
Top UP-regulated	ILMN_2343774
Top DOWN-regulated	ILMN_1784493

3.1 Boxplot dei geni selezionati

I boxplot sono stati costruiti per visualizzare la distribuzione dell'espressione dei due geni più rappresentativi tra i DEG. Il gene ILMN_2343774 è stato scelto perché ha il logFC massimo, mentre ILMN_1784493 è stato scelto perché ha il logFC minimo. Questi due grafici permettono di verificare visivamente che i due geni mostrino un comportamento diverso nei campioni Normal e Tumor.




Figura 3. Boxplot del gene più up-regulated (ILMN_2343774). Il gruppo Tumor mostra valori di espressione più elevati rispetto al gruppo Normal.




Figura 4. Boxplot del gene più down-regulated (ILMN_1784493). Il gruppo Normal mostra valori di espressione più elevati rispetto al gruppo Tumor.

3.2 Heatmap dei top 50 DEG

La heatmap è stata costruita utilizzando i top 50 geni differenzialmente espressi ordinati per significatività. I valori sono stati scalati per riga, così da evidenziare il comportamento relativo di ciascun gene tra i campioni indipendentemente dal livello assoluto di espressione.

Il clustering dei campioni mostra una separazione chiara tra Normal e Tumor. Questo risultato è coerente con l'analisi differenziale e suggerisce che i geni selezionati descrivano differenze trascrittomiche rilevanti tra i due gruppi.



Figura 5. Heatmap dei top 50 geni differenzialmente espressi. La barra superiore indica il gruppo di appartenenza dei campioni.

3.3 Analisi delle Componenti Principali (PCA)

La PCA è stata calcolata usando tutti i 1760 geni differenzialmente espressi. L’obiettivo non era quello di selezionare nuovi geni, ma verificare se i DEG già identificati fossero sufficienti a separare i campioni in base al gruppo biologico.

La prima componente principale spiega il 57.51% della varianza, mentre la seconda componente principale spiega il 9.36%. Complessivamente PC1 e PC2 spiegano circa il 66.87% della variabilità totale. Nel grafico si osserva una separazione netta tra Normal e Tumor soprattutto lungo PC1.

Componente	Varianza spiegata
PC1	57.51%
PC2	9.36%
PC1 + PC2	66.87%




Figura 6. PCA dei geni differenzialmente espressi. I campioni Normal e Tumor formano due gruppi distinti, separati principalmente lungo PC1.

3.4 Interpretazione complessiva

Nel complesso, i grafici supportano visivamente i risultati ottenuti nella fase di analisi differenziale. I boxplot mostrano due esempi chiari di geni con espressione diversa tra i gruppi, la heatmap evidenzia pattern coerenti con la distinzione tra tessuto tumorale e tessuto normale e la PCA conferma che i profili dei DEG permettono di separare chiaramente i campioni Normal e Tumor.

Codice R utilizzato

```
# Selezione del gene piu up-regulated e piu down-regulated
top_up <- deg$Gene[which.max(deg$logFC)]
top_down <- deg$Gene[which.min(deg$logFC)]

top_up
top_down

# Boxplot gene up-regulated
up_values <- data.frame(
  Expression = as.numeric(expr_filtered[top_up, ]),
  Group = metadata$Group,
  Patient = metadata$Patient
)
boxplot(Expression ~ Group, data = up_values,
  col = c("lightblue", "salmon"),
  main = paste("Top Up-regulated Gene:", top_up),
  xlab = "Group", ylab = "Expression")
stripchart(Expression ~ Group, data = up_values,
  vertical = TRUE, method = "jitter",
  pch = 20, col = "black", add = TRUE)

# Boxplot gene down-regulated
down_values <- data.frame(
  Expression = as.numeric(expr_filtered[top_down, ]),
  Group = metadata$Group,
  Patient = metadata$Patient
)
boxplot(Expression ~ Group, data = down_values,
  col = c("lightblue", "salmon"),
  main = paste("Top Down-regulated Gene:", top_down),
  xlab = "Group", ylab = "Expression")
stripchart(Expression ~ Group, data = down_values,
  vertical = TRUE, method = "jitter",
  pch = 20, col = "black", add = TRUE)

# Heatmap dei top 50 DEG
library(pheatmap)
top_n <- 50
top_deg_genes <- deg$Gene[1:top_n]
heatmap_matrix <- expr_filtered[top_deg_genes, ]
annotation_col <- data.frame(Group = metadata$Group)
rownames(annotation_col) <- metadata$Sample
pheatmap(heatmap_matrix, scale = "row",
  show_rownames = TRUE, show_colnames = FALSE,
  annotation_col = annotation_col,
  main = paste("Heatmap of Top", top_n, "Differentially Expressed Genes"))

# PCA sui DEG
pca_matrix <- t(expr_filtered[deg$Gene, ])
pca_res <- prcomp(pca_matrix, scale. = TRUE)
summary(pca_res)

pca_df <- data.frame(
  PC1 = pca_res$x[, 1],
  PC2 = pca_res$x[, 2],
  Group = metadata$Group,
  Sample = metadata$Sample
)
plot(pca_df$PC1, pca_df$PC2,
  col = ifelse(pca_df$Group == "Tumor", "red", "blue"),
  pch = 19, xlab = "PC1", ylab = "PC2",
  main = "PCA of Differentially Expressed Genes")
legend("topright", legend = c("Normal", "Tumor"),
  col = c("blue", "red"), pch = 19)
```

Sezione 4 - Esportazione dei risultati

Obiettivo della fase

In questa fase è stata salvata in un file di testo la lista finale dei geni differenzialmente espressi ottenuti dall'analisi. L'obiettivo era produrre una tabella semplice da controllare e riutilizzare nelle fasi successive, in particolare per l'annotazione dei geni e per l'enrichment analysis.

4.1 Costruzione della tabella finale

La tabella finale è stata costruita a partire dall'oggetto `deg`, cioè dall'elenco dei geni che hanno superato le soglie definite nella Fase 2: `|logFC| >= 1` e `p-value aggiustato <= 0.05`. Sono state mantenute solo le colonne più utili per la lettura dei risultati: identificativo del gene, p-value aggiustato, logFC e direzione della regolazione.

4.2 Descrizione delle colonne esportate

Colonna	Descrizione
Gene	Identificativo della sonda/gene differenzialmente espresso
adj.P.Val	p-value corretto con metodo FDR
logFC	Differenza media di espressione Tumor - Normal in scala log2
Regulation	Indicazione Upregulated o Downregulated in base al segno del logFC

4.3 Interpretazione

Il file finale contiene 1760 geni differenzialmente espressi: 418 upregulated e 1342 downregulated.

Le prime righe **del file** mostrano i geni più significativi ordinati in base al p-value aggiustato. In questo caso i primi geni risultano downregulated nei campioni tumorali rispetto ai controlli normali matched.

Codice R utilizzato

```
# =====
# 5. ESPORTAZIONE DEI RISULTATI
# =====

final_results <- data.frame(
  Gene = deg$Gene,
  adj.P.Val = deg$pval_adj,
  logFC = deg$logFC,
  Regulation = ifelse(
    deg$logFC > 0,
    "Upregulated",
    "Downregulated"
  )
)

final_results <- final_results[order(final_results$adj.P.Val), ]

head(final_results)
dim(final_results)
table(final_results$Regulation)

write.table(
  final_results,
  file = file.path(dirResults, "Differentially_Expressed_Genes.txt"),
  sep = "\t",
  quote = FALSE,
  row.names = FALSE
)

file.exists(
  file.path(dirResults, "Differentially_Expressed_Genes.txt")
)
```

Sezione 5 - Analisi di arricchimento funzionale

Obiettivo della fase

Dopo aver ottenuto la lista dei geni differenzialmente espressi, è stata eseguita un'analisi di arricchimento funzionale con EnrichR. L'obiettivo non era più identificare singoli geni, ma capire se l'elenco dei DEG fosse associato a processi biologici o pathway specifici.

Prima dell'analisi è stato necessario convertire gli identificativi delle sonde Illumina in simboli genici, perché EnrichR lavora principalmente con gene symbols.

5.1 Preparazione della lista genica

La lista di partenza era costituita dai 1760 geni differenzialmente espressi ottenuti nella fase precedente. Poiché questi geni erano identificati come sonde Illumina, è stato usato il pacchetto illuminaHumanv3.db per convertirli in simboli genici. Dopo aver rimosso valori non annotati e duplicati, sono rimasti 1451 gene symbols unici.

Elemento	Risultato
Geni differenzialmente espressi iniziali	1760
Database di annotazione	illuminaHumanv3.db
Gene symbols unici ottenuti	1451
Esempi di gene symbols	ITLN2, FABP4, FAM107A, FMO2, GPIHBP1, MCEMP1

5.2 Database utilizzati in EnrichR

L'analisi è stata eseguita su tre database, i quali sono stati scelti per ottenere una visione complementare dei risultati: processi biologici, pathway metabolici/signaling e pathway Reactome.

Database	Scopo
GO_Biological_Process_2023	Processi biologici arricchiti
KEGG_2021_Human	Pathway biologici e cellulari
Reactome_2022	Pathway funzionali curati in Reactome

5.3 Risultati GO Biological Process

I risultati GO mostrano un arricchimento di processi legati alla risposta a citochine, angiogenesi, proliferazione cellulare, infiammazione e motilità cellulare. Questi processi sono coerenti con un confronto tra tessuto tumorale e tessuto normale.

Termine GO	Overlap	Adjusted p-value
Cellular Response To Cytokine Stimulus	72/308	1.11e-15
Regulation Of Angiogenesis	55/205	1.42e-14
Regulation Of Cell Population Proliferation	118/766	4.05e-12
Inflammatory Response	52/236	2.97e-10
Positive Regulation Of Angiogenesis	35/119	2.97e-10
Positive Regulation Of Cell Motility	48/221	3.15e-09

5.4 Risultati KEGG

Nei risultati KEGG compaiono pathway associati a risposta immunitaria, fagocitosi, complemento e coagulazione. Alcuni pathway hanno nomi legati a infezioni, ma in questo contesto non indicano necessariamente un'infezione nei campioni: compaiono perché condividono geni coinvolti in infiammazione, HLA, complemento e immunità.

Pathway KEGG	Overlap	Adjusted p-value
Phagosome	40/152	1.34e-10
Leishmaniasis	27/77	2.63e-10
Complement and coagulation cascades	28/85	3.94e-10
Osteoclast differentiation	33/127	4.73e-09
Staphylococcus aureus infection	28/95	4.73e-09
Hematopoietic cell lineage	27/99	5.87e-08

5.5 Risultati Reactome

I risultati Reactome confermano il coinvolgimento del sistema immunitario, dell'immunità innata, delle interazioni vascolari, della degranulazione dei neutrofili e della matrice extracellulare. Questi pathway descrivono bene componenti del microambiente tumorale.

Pathway Reactome	Overlap	Adjusted p-value
Immune System	241/1943	1.55e-14
Innate Immune System	146/1035	1.92e-12
Cell Surface Interactions At Vascular Wall	37/134	3.21e-10
Neutrophil Degranulation	79/468	4.52e-10
Extracellular Matrix Organization	55/291	1.26e-08
Interleukin-4 And Interleukin-13 Signaling	29/107	7.96e-08

Codice R utilizzato

```
library(AnnotationDbi)
library(illuminaHumanv3.db)
library(enrichR)

# Conversione Probe ID -> Gene Symbol
probe_ids <- final_results$Gene

gene_symbols <- mapIds(
  illuminaHumanv3.db,
  keys = probe_ids,
  column = "SYMBOL",
  keytype = "PROBEID",
  multiVals = "first"
)

gene_symbols <- na.omit(gene_symbols)
gene_symbols <- unique(gene_symbols)

length(gene_symbols)
head(gene_symbols)

# Database EnrichR
dbs <- listEnrichrDbs()
head(dbs)

databases <- c(
  "GO_Biological_Process_2023",
  "KEGG_2021_Human",
  "Reactome_2022"
)

# Enrichment analysis
enrich_results <- enrichr(gene_symbols, databases)

GO_results <- enrich_results[["GO_Biological_Process_2023"]]
KEGG_results <- enrich_results[["KEGG_2021_Human"]]
Reactome_results <- enrich_results[["Reactome_2022"]]

head(GO_results)
head(KEGG_results)
head(Reactome_results)

# Export risultati
write.table(GO_results,
  file = file.path(dirResults, "GO_results_GSE32863.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)
write.table(KEGG_results,
  file = file.path(dirResults, "KEGG_results_GSE32863.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)
write.table(Reactome_results,
  file = file.path(dirResults, "Reactome_results_GSE32863.txt"),
  sep = "\t", quote = FALSE, row.names = FALSE)
```

Sezione 6 - Analisi aggiuntiva e ricerca bibliografica

Obiettivo della fase

In questa fase ho approfondito i risultati ottenuti dall'analisi di arricchimento funzionale, consultando banche dati biologiche e alcune fonti bibliografiche. L'obiettivo non era effettuare un'analisi clinica dettagliata, ma interpretare in modo generale i principali processi biologici associati ai geni differenzialmente espressi.

6.1 Interpretazione dei risultati

Dall'analisi con EnrichR sono emersi diversi termini legati alla risposta immunitaria, all'infiammazione, all'angiogenesi, al complemento/coagulazione e alla matrice extracellulare.

Questi risultati sono coerenti con il confronto tra tessuto tumorale e tessuto normale, perché un tumore può modificare non solo l'espressione di singoli geni, ma anche processi biologici più ampi. In particolare, la presenza di termini legati a citochine e infiammazione suggerisce un coinvolgimento della comunicazione cellulare e della risposta del tessuto. I termini associati all'angiogenesi possono invece essere collegati alla formazione di nuovi vasi sanguigni, un processo spesso rilevante nei tessuti tumorali.

Nei risultati KEGG compaiono anche pathway con nomi riferiti a infezioni, come "Leishmaniasis" o "Staphylococcus aureus infection". In questo caso non li ho interpretati come presenza di infezione nei campioni, ma come pathway che condividono geni coinvolti nella risposta immunitaria e infiammatoria.

Anche i risultati Reactome, come "Immune System", "Innate Immune System" ed "Extracellular Matrix Organization", confermano che molti geni differenzialmente espressi sono collegati al microambiente tumorale, cioè all'insieme dei segnali e delle strutture che circondano le cellule tumorali.

6.2 Conclusione

Nel complesso, questa fase ha permesso di passare da una lista di geni differenzialmente espressi a un'interpretazione biologica più generale. I risultati non dimostrano direttamente un meccanismo causale, ma suggeriscono che le differenze tra campioni tumorali e normali siano associate soprattutto a processi immunitari, infiammatori, vascolari e strutturali.